面向严格联合位姿约束的机械臂局部收敛增强软演员-评论家方法

1st Ze Cui
School of Mechatronic Engineering and Automation
Shanghai University
Shanghai, China
cuize0421@126.com

2nd Xuefeng Ji
School of Mechatronic Engineering and Automation
Shanghai University
Shanghai, China
15157376112@163.com

3rd Jiaxiang Han
School of Mechatronic Engineering and Automation
Shanghai University
Shanghai, China
13403858438@163.com

4th Hai Huang
School of Mechatronic Engineering and Automation
Shanghai University
Shanghai, China
huanghaha@shu.edu.cn

摘要—已有研究已验证深度强化学习在随机末端位姿到达中的可行性，但当成功容差从厘米级逐步收紧到毫米级时，策略性能可能在目标邻域明显退化，表现为联合约束难以同时满足，并出现确定性保持失败。本文研究在不缩小目标分布和不引入解析控制器的条件下，如何改善软演员评论家（Soft Actor-Critic，SAC）在高精度联合位姿控制中的局部收敛表现。我们引入局部Jacobian、联合精度优化信号和精度边界经验回放，形成完整增强框架。课程逐级收紧位置与姿态容差，并采用多种子确定性评估作为课程推进判据。在统一的随机目标分布、网络结构、精度课程和固定训练预算下，所提出的方法在 10 mm/0.10 rad 联合容差下取得 96.35% 的成功率，并进一步达到 1 mm/0.025 rad 的严格联合容差，在该条件下取得 97.20% 的确定性评估成功率。

Index Terms—强化学习，软演员评论家，机械臂控制，联合位姿，课程学习，局部收敛

I. 引言

随机六维末端位姿到达要求策略同时处理三维位置和三维姿态。SAC 以最大熵目标提高了连续控制中的探索效率 [1]，课程学习则可以先训练较容易的任务，再逐步收紧目标容差 [2]。这些方法能够支持较宽松的随机位姿到达，但并不保证策略在目标邻域持续产生方向和幅值合适的微调动作，从而稳定满足严格的联合位姿约束。

已有研究已经报告了随机位姿强化学习控制的可行性。例如，MAPPO-IK 在随机位置与姿态任务上获得了毫米级的位置误差和较小的姿态误差 [5]；连续位姿表示与课程学习也被用于缓解位姿表示不连续带来的训练问题 [6]。然而，部分现有随机位姿到达工作主要报告最终成功率或终端误差，对成功容差持续收紧后的目标邻域性能退化缺少专门分析。

本文关注以下问题：在目标分布、动作空间和训练预算保持不变时，如何降低高精度联合位姿控制的局部收敛退化？围绕目标邻域的方向辨识、误差优化和经验覆盖，本文构建增强框架，并通过基线比较和子项消融分析其性能变化。

本文的主要贡献如下：

- 面向严格联合位姿容差，研究 SAC 由全局到达向目标邻域精细收敛过渡时的性能退化问题，并建立固定预算、多阶段精度课程与确定性评估协议；
- 在已有关键点联合位姿表达基础上，引入 Keypoint Jacobian 局部运动学信息、联合精度优化信号和精度边界经验重采样，构造 SAC 增强框架；

- 通过统一训练预算下的基线比较和关键子项消融，验证所提出框架在不同精度阶段的局部收敛性能。

II. 相关工作

A. 连续控制与课程学习

SAC 通过最大熵强化学习目标在探索和回报之间取得平衡 [1]。课程学习从易到难组织训练任务，能够改善难任务的可学习性 [2]；面向精确运动规划的自动课程方法也表明，按任务复杂度组织训练分布有助于机械臂学习 [9]。在机械臂场景中，课程学习主要有助于缓解宽范围任务中的探索与学习难度，但并未直接针对目标邻域的细粒度动作生成。

B. 位姿表示与经验回放

六维位姿中的姿态表示会影响误差连续性和策略梯度。连续位姿表示已被用于缓解姿态表示的不连续性，并结合经验回放与课程学习改善训练收敛性能 [6]；经验回放研究则通过重新标记目标或调整样本采样分布提高有效经验利用率 [3], [4]。Portela 等人使用末端对齐的三关键点表达联合位姿 [7]，观测—动作空间对齐研究也表明，匹配控制接口和奖励结构的表示可能带来更高到达成功率 [10]。本文在已有关键点位姿表达基础上，进一步引入局部 Jacobian 信息、联合精度优化和精度边界经验回放，以研究严格联合位姿容差下的局部收敛性能。

复杂奖励中的多个目标之间可能存在竞争与权衡，已有工作据此研究奖励课程以及位置、姿态相关奖励项的非线性融合 [11], [12]；聚类回放和分布感知采样则从状态覆盖和数据分布保持角度说明了选择性采样的价值 [13], [14]。

III. 问题定义

考虑一个六自由度机械臂。时刻 t 的关节状态为 q_t，策略输出关节速度动作 $a_t = \dot{q}_t$，末端位姿为 $T(q_t) = [R(q_t), p(q_t)]$，目标位姿为 $T_g = [R_g, p_g]$。位置误差和姿态误差分别写为

$$e_p = \|p(q_t) - p_g\|_2, \qquad e_R = \|\log(R_g^{\mathsf{T}} R(q_t))\|_2. \quad (1)$$

给定位置阈值 ϵ_p^l 和姿态阈值 ϵ_R^l，定义最差归一化约束

$$\rho_t^l = \max\left(\frac{e_{p,t}}{\epsilon_p^l}, \frac{e_{R,t}}{\epsilon_R^l}\right). \quad (2)$$

定义成功保持计数 h_t。当联合阈值连续满足 $H = 5$ 个控制步时，档位 l 的成功事件定义为

$$\mathcal{S}_l = \mathbb{I}[\rho_t^l \le 1 \ \wedge \ h_t \ge H]. \quad (3)$$

训练目标是在完整随机目标分布上最大化 $\Pr(\mathcal{S}_l = 1)$。

IV. 方法

A. 整体框架与基础表征基线

KP-SAC-Base 作为本文的基础对比方法，采用 SAC 策略框架，其观测同时包含显式位置—姿态误差和 Portela 等人提出的三关键点位姿表示，并采用关键点距离与进度奖励以及普通经验回放。在相同目标分布、网络结构、SAC 超参数、精度课程和训练预算下，Full 在该基线上进一步引入 Keypoint Jacobian、联合精度优化信号和精度边界经验回放。M1、M2 和 M3 分别在 Full 基础上移除 joint bottleneck shaping、Precision Boundary Replay 和 Keypoint Jacobian 输入。

B. 关键点与局部运动学输入

本文的关键点构造参考 Portela 等人的关键点位姿表示 [7]：在末端坐标系中构造以末端位置为中心、方向随末端姿态旋转的立方体，并选取三个具有直接对应关系的顶点。三个具有固定对应关系的非共线点能够共同编码末端平移与旋转变化；与直接拼接欧拉角或四元数相比，这种几何表示把联合位姿误差转换为同一坐标空间中的点误差。针对本文的固定基座 UR5，立方体边长为 0.5 m；这是用于位姿编码的虚拟几何尺度，而非实际工具尺寸。三个顶点在工具坐标系中的偏移为

$$u_1 = \tfrac{0.5}{2}[1,1,1]^{\mathsf{T}}, \qquad u_2 = \tfrac{0.5}{2}[1,-1,-1]^{\mathsf{T}},$$
$$u_3 = \tfrac{0.5}{2}[-1,1,-1]^{\mathsf{T}}.$$

目标关键点与当前关键点均由对应位姿旋转这些偏移后平移得到。设末端及工具上选取的关键点坐标为 $x_i(q)$，目标关键点为 x_i^g。关键点距离为

$$d_k = \frac{1}{K}\sum_{i=1}^{K} \|x_i(q) - x_i^g\|_2. \quad (4)$$

对每个关键点，局部速度满足 $\dot{x}_i = J_i(q)\dot{q}$，其中 $J_i \in \mathbb{R}^{3\times 6}$ 为关键点 Jacobian。近期 Jacobian 探索式强化学习工作也采用局部 Jacobian 特征增强状态表示

[8]。Full 将归一化的关键点误差、关键点进度和局部 Jacobian 信息与标准位姿误差拼接为策略输入。具体地，关键点误差除以 0.65 m 后裁剪到 $[-1,1]$，每个 J_i 除以 1.1 后裁剪到 $[-1,1]$；三个 J_i 拼接为 $9\times 6=54$ 维。Base 的观测为 108 维，Full 为 162 维。为控制网络参数规模一致，M3 保持相同输入维度，并将对应的 54 维 Jacobian 特征置零。观测还包含归一化关节位置与速度、显式位置/姿态误差、末端速度和安全相关特征。Jacobian 根据 UR5 运动学模型和当前关节状态计算，并作为策略观测输入。

C. 联合优化信号

为使奖励同时反映位置和姿态误差的改善，Full 使用位置、姿态和关键点进度的连续误差改善信号。令 $\Delta e_p = e_{p,t-1}-e_{p,t}$、$\Delta e_R = e_{R,t-1}-e_{R,t}$，奖励函数可简化写为

$$r_t = r_{\text{task}} + \lambda_p \Delta e_p + \lambda_R \Delta e_R + \lambda_k \Delta d_k - r_{\text{cost}}. \tag{5}$$

其中 r_{task} 表示联合成功奖励，r_{cost} 包含动作和碰撞代价。KP-SAC-Base 只保留关键点跟踪、关键点进度、连续成功奖励以及动作、碰撞等代价项；Full 与 M1–M3 额外共享按当前档位归一化的 precision quality 和 hold/leave。令 $\rho_p = e_p/\epsilon_p^l$、$\rho_R = e_R/\epsilon_R^l$，precision quality 定义为

$$q_{\text{pq}} = \exp\left[-\frac{\rho_p/0.05+\rho_R/0.10}{2}\right], \tag{6}$$

其中 0.05 和 0.10 为固定经验尺度参数。其进度项系数为 2.0；当当前和下一状态均在 joint precision 区域内时加入 0.15 的 hold reward，若从区域内离开则加入 0.2 的 leave penalty。Full 的 joint bottleneck shaping 在这些阈值型信号之上，为最差归一化约束增加连续非终止势函数：

$$\rho_b(s_t) = \max\left(\frac{e_{p,t}}{\epsilon_p^l}, \frac{e_{R,t}}{\epsilon_R^l}\right), \tag{7}$$

$$\Phi_b(s_t) = 5\exp[-\rho_b(s_t)/2], \tag{8}$$

$$r_{b,t} = (1-d_t)[\gamma\Phi_b(s_{t+1}) - \Phi_b(s_t)]. \tag{9}$$

其中，$d_t=1$ 表示成功、超时、碰撞或其他硬失败终止。所有终止转移样本的 Bottleneck shaping 均置零，终止结果由专门的成功或失败项处理，从而避免势函数在终止状态引入额外的终止偏置。M1 去除该 bottleneck 项，但保留 precision quality 和 hold/leave。

表 I
Full 的关键训练组成

组件	定义与参数
Precision quality	$q_{\text{pq}} = \exp[-(\rho_p/0.05+\rho_R/0.10)/2]$；进度系数 2.0
Hold / leave	保持奖励 $=0.15$；离开联合精度区域惩罚 $=0.2$
Success subset	成功回合（$\mathcal{S}_l=1$）中的全部转移样本
Boundary subset	当前状态满足 $0.8\le\rho_t^l\le 1.5$
Replay ratio	ordinary : Success : Boundary $=0.6:0.2:0.2$
Bottleneck	$5\exp(-\rho_b/2)$ 的非终止势函数

Full 的关键训练组成与固定参数见表 I；其中 Success subset 为成功回合（$\mathcal{S}_l=1$）中的全部转移样本，Boundary subset 由当前状态的 $0.8\le\rho_t^l\le 1.5$ 判定。

D. 精度边界经验回放

宽松课程阶段产生的经验不能充分覆盖严格阈值附近的状态。对转移样本 (s_t,a_t,r_t,s_{t+1})，Full 依据当前状态的 $0.8\le\rho_t^l\le 1.5$ 判定 Boundary subset；s_{t+1} 用于区分保持、退出或单项失败。该划分提高联合精度边界附近状态—动作样本的采样频率。M2 移除 precision boundary replay。

E. 自动精度课程

课程档位及阈值见表 II。所有方法共享同一 precision action scaling：令 $\rho_t=\max(e_{p,t}/\epsilon_p, e_{R,t}/\epsilon_R)$，当 $\rho_t\le 1$ 时 $g(\rho_t)=0.05+0.05\rho_t$，否则 $g(\rho_t)=0.10+0.90\min(\rho_t-1,1)^2$，实际关节速度为 $\dot{q}_{\text{cmd}}=g(\rho_t)(0.7a_t)$。每档至少累计 50 000 个转移样本；每累计 300 000 个转移样本触发一次确定性探针评估。探针评估使用三个评估种子、每种子 300 个回合；通过后再使用每种子 1000 个回合的确认评估，确认通过后推进至下一档位。训练日志中的在线随机策略成功率仅作为诊断。

表 II
精度课程档位

档位 l	ϵ_p / mm	ϵ_R / rad
$L0$	100	0.30
$L1$	80	0.24
$L2$	64	0.192
$L3$	51.2	0.1536
$L4$	50	0.10
$L5$	25	0.10
$L6$	10	0.10
$L7$	5	0.10
$L8$	2.5	0.10
$L9$	2	0.10
$L10$	1.5	0.10
$L11$	1	0.10
$L12$	1	0.05
$L13$	1	0.025

V. 实验设置

A. 环境与训练

IK 仅用于离线目标可达性过滤，不参与策略动作生成。实验在 PyBullet UR5 无障碍环境中进行。目标位置从末端初始位置出发，先采样 $d \sim U(0.03, 0.50)$ m 和单位球面均匀方向，再取 $p_g = p_0 + d\,v$；目标姿态差采样 $\theta \sim U(0.03, \pi)$，旋转轴从三维标准正态归一化得到，并以轴角增量与初始姿态复合。候选目标还需通过工作空间、IK 可达性和自碰撞过滤；经筛选后的目标分布在各精度档位和方法间保持不变。每个回合最多运行 500 个控制步，物理步长为 0.00417 s、控制周期为 0.05 s，初始关节状态在关节限位内随机采样并过滤自碰撞。策略动作为关节速度指令，所有方法使用相同的 SAC 隐藏层结构、超参数、目标分布和 6,000,000 个转移样本预算。Full 与 KP-SAC-Base 使用训练种子 11001 和 11002；M1、M2、M3 使用预先指定的单一训练种子 11001；最终冻结评估使用独立的测试种子 31001、31002 和 31003。对各策略检查点冻结策略后进行确定性评估，每个组合运行 1000 个回合。由于不同方法最终达到的最高档位不同，主表报告共同 L6 以及各方法实际达到的最高档位；不存在的档位记为 N/A。单训练种子消融仅作为关键子项与性能变化关系的辅助证据，不用于估计跨训练随机种子的统计方差。

表 III
对比方法与组件配置

方法	方法配置
KP-SAC-Base	显式位姿误差 + 三关键点位姿表示；关键点奖励；ordinary replay。
Full	Base + Keypoint Jacobian + joint precision optimization + Success/Boundary Replay。
M1	Full w/o joint bottleneck shaping。
M2	Full w/o Precision Boundary Replay。
M3	Full with Keypoint Jacobian features zeroed。

各对比方法的组件配置见表 III。

B. 评价指标

主要指标包括联合成功率、超时率、碰撞率以及终端位置和姿态误差的 P95。P95 在全部冻结评估回合上计算，同时包含成功和失败回合。

VI. 结果与分析

A. 固定预算下的课程推进结果

本文以固定训练预算下的课程推进作为主要评估结果。冻结评估覆盖共同 L6 和各方法实际达到的最高档位；每个方法、测试种子和档位运行 1000 个回合。共同 L6 用于横向比较，各方法最高档位用于描述固定预算下的课程推进程度。Full、M1 和 M2 达到 L13，M3 达到 L11；Base 的两个训练种子分别达到 L7 和 L6。对于未达到 L13 的方法，不报告 L13 结果。所有方法均采用本文定义的统一升档判据。

B. 主结果

表 IV 汇总冻结策略在三个独立测试种子上的成功率均值和标准差；Full 与 Base 的 L6 结果汇总两个训练种子，消融结果对应预先指定的单一训练种子。关键终端误差 P95（位置 mm/姿态 rad）为：Base-L6 $168.85 \pm 7.77 / 0.609 \pm 0.040$, Full-L6 $9.31 \pm 0.09 / 0.098 \pm 0.000$，Full-L13 $0.098 \pm 0.000 / 0.024 \pm 0.000$，M2-L13 $0.99 \pm 0.01 / 0.031 \pm 0.002$, M3-L11 $0.351 \pm 0.056 / 0.097 \pm 0.001$。M1 的终端误差与 Full 接近。

在共同 L6，Full 将成功率由 84.75% 提高至 96.35%，同时终端位置 P95 由 168.85 mm 降至 9.31

表 IV
不同精度档位的冻结确定性成功率（均值 ± 标准差，%）

方法	成功率均值 / %			
	L6	L11	L13	最高档位
KP-SAC-Base	84.75 ± 0.62	N/A	N/A	L7 / L6
Full	96.35 ± 0.36	N/A	97.20 ± 1.07	L13
M1	95.90 ± 0.40	N/A	97.60 ± 0.46	L13
M2	97.50 ± 0.26	N/A	89.23 ± 0.85	L13
M3	91.13 ± 0.95	77.13 ± 0.51	N/A	L11

mm。此外，Full 在固定训练预算内进一步推进至 1 mm/0.025 rad 的 L13，而 Base 的两个训练种子分别达到 L7 和 L6。严格档位的比较仅针对实际达到该档位的方法进行。

C. 消融结果

M1、M2 和 M3 分别在 L6 达到 95.90%、97.50% 和 91.13%。M3 的终端位置误差 P95 增大，并且只推进到 L11。Full 在 L13 的成功率为 97.20%，M2 在同一档位为 89.23%；M2 的位置误差 P95 为 0.99 mm，姿态误差 P95 为 0.031 rad，退化主要集中于姿态误差尾部。M1 在 L13 的成功率为 97.60%，与 Full 的 97.20% 接近，当前实验中尚未观察到 Bottleneck shaping 的明显独立增益。

VII. 讨论与局限

本文结论限定在无障碍 PyBullet 仿真和给定随机目标分布内。仿真没有真实编码器噪声、减速器间隙、标定误差、视觉误差和通信延迟，因此 1 mm 表示仿真中的位置成功容差，不能替代真实机器人精度验证。后续工作需要加入动力学扰动、观测噪声和真实机器人验证。M1–M3 采用单一训练种子，相关结果用于比较关键子项移除后的性能变化。

VIII. 结论

本文提出了一个面向严格联合位姿约束的局部收敛增强 SAC 框架。完整增强框架在共同 L6（10 mm/0.10 rad）将成功率从 KP-SAC-Base 的 84.75% 提高到 96.35%，并进一步达到 1 mm/0.025 rad 的最高精度档位。去除 Boundary Replay 后，M2 的最高档位成功率为 89.23%；将 Jacobian 特征置零后，M3 仅达到 L11，成功率为 77.13%。当前实验中尚未观察到 Bottleneck shaping 的明显独立增益。

致谢

本节在投稿前填写基金、平台和计算资源信息。

参考文献

[1] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, “Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor,” in Proc. ICML, vol. 80, pp. 1861–1870, 2018. [Online]. Available: https://proceedings.mlr.press/v80/haarnoja18b.html

[2] Y. Bengio, J. Louradour, R. Collobert, and J. Weston, “Curriculum learning,” in Proc. ICML, pp. 41–48, 2009, doi: 10.1145/1553374.1553380.

[3] M. Andrychowicz et al., “Hindsight experience replay,” in Advances in Neural Information Processing Systems, vol. 30, 2017. [Online]. Available: https://papers.nips.cc/paper/7090-hindsight-experience-replay

[4] T. Schaul, J. Quan, I. Antonoglou, and D. Silver, “Prioritized experience replay,” in Proc. ICLR, 2016. [Online]. Available: https://arxiv.org/abs/1511.05952

[5] Y. Zhao et al., “Inverse kinematics solution and control method of 6-degree-of-freedom manipulator based on deep reinforcement learning,” Scientific Reports, vol. 14, Art. no. 12467, 2024, doi: 10.1038/s41598-024-62948-6.

[6] Y. Hu et al., “Deep reinforcement learning-based trajectory planning with continuous pose representation for 6-DoF free-floating space robot,” Aerospace Science and Technology, vol. 166, Art. no. 110540, 2025, doi: 10.1016/j.ast.2025.110540.

[7] T. Portela, A. Cramariuc, M. Mittal, and M. Hutter, “Whole-Body End-Effector Pose Tracking,” in Proc. IEEE Int. Conf. Robot. Autom. (ICRA), pp. 11205–11211, 2025, doi: 10.1109/ICRA55743.2025.11127964.

[8] Y. Tian, C. K. Ng, and H. Ren, “Jacobian Exploratory Dual-Phase Reinforcement Learning for Dynamic Endoluminal Navigation of Deformable Continuum Robots,” in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst. (IROS), pp. 21559–21565, 2025, doi: 10.1109/IROS60139.2025.11247575.

[9] D.-S. Cho, J.-M. Cho, and W.-T. Kim, “Guided deep reinforcement learning framework using automated curriculum scheme for accurate motion planning,” Engineering Applications of Artificial Intelligence, vol. 139, Art. no. 109541, 2025, doi: 10.1016/j.engappai.2024.109541.

[10] V. Bhat, Z. Suleymanova, and C. Bellinger, “Beyond Information Sufficiency: Observation-Action Space Alignment in Robotic Reinforcement Learning,” in Proc. Canadian Conf. Artificial Intelligence, PMLR, vol. 318, pp. 1052–1059, 2026. [Online]. Available: https://proceedings.mlr.press/v318/bhat26a.html

[11] K. Freitag, K. Ceder, R. Laezza, K. Åkesson, and M. H. Chehreghani, “Curriculum Reinforcement Learning for Complex Reward Functions,” arXiv:2410.16790v2 [cs.LG], 2024. [Online]. Available: https://arxiv.org/abs/2410.16790

[12] K. Jiang, Z. Fu, J. Guo, W. Zhang, and H. Chen, "Learning Whole-Body Loco-Manipulation for Omni-Directional Task Space Pose Tracking With a Wheeled-Quadrupedal-Manipulator," IEEE Robotics and Automation Letters, vol. 10, no. 2, pp. 1481–1488, 2025, doi: 10.1109/LRA.2024.3519856.

[13] M. Li, T. Huang, and W. Zhu, "Clustering experience replay for the effective exploitation in reinforcement learning," Pattern Recognition, vol. 131, Art. no. 108875, 2022, doi: 10.1016/j.patcog.2022.108875.

[14] A. Garg, A. R. Sharma, A. Arora, and S. Verma, "Distribution-aware sampling of replay buffer for mitigating catastrophic forgetting," Information Sciences, vol. 753, Art. no. 123640, 2026, doi: 10.1016/j.ins.2026.123640.